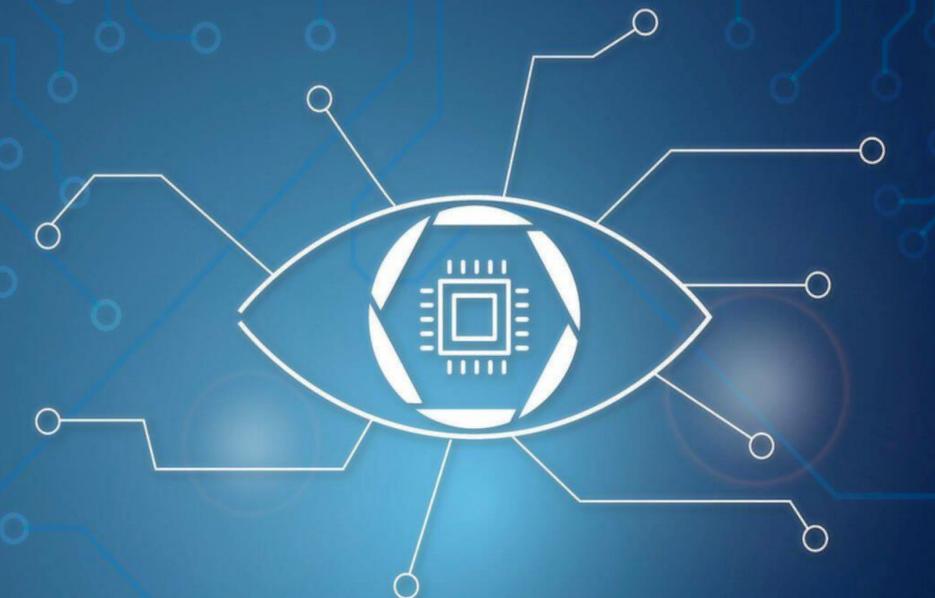
innovale





Segmentarea celulelor din imagini medicale

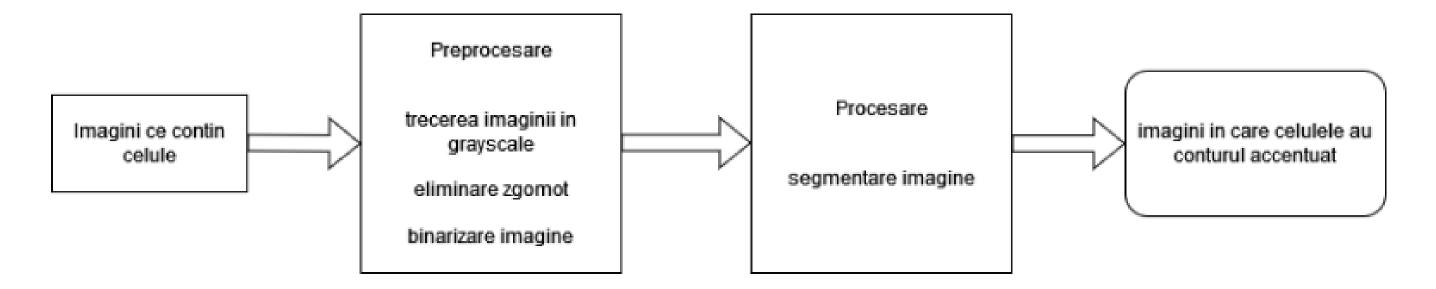
Agavriloaei Marina Moisuc Raluca-Elena

1. Context & Motivație

- Context: Cerința proiectului este realizarea unui algoritm care poate segmenta cu o acuratețe cât mai ridicată celulele din imagini medicale
- Motivație: Segmementarea automatizată a celulelor economisește timp, si poate ajuta la detecția timpurie a anomaliilor, ajuta la reducerea erorilor umane și poate ajuta la monitorizarea evoluției bolilor
- Obiectivul proiectului: De a evidenția forma celulelor , prin conturarea marginilor acestora și de a crea maști care suprapuse peste o imaginea initială ne vor arata regiuni de interes (în cazul dat doar celulele, sau doar fundalul zonei in care se afla celulele)

2. Arhitectura preliminară a soluției

Schema arhitecturii:



- Descrierea componentelor:
- Cei doi algoritmi prezentati in cod au in comun:
- În etapa de preprocesare utilizam metoda Otsu pentru gasirea unui threshold optim pentru binarizarea imaginii.
- Facem egalizarea de histograma pentru distibuirea intensitatilor luminioase în cazul imaginilor cu un interval limitat de valori

2. Arhitectura preliminară a soluției

- 1. gray_img = cv2.cvtColor(img, cv2.COLOR_BGR2GRAY)
- 2. clahe = cv2.createCLAHE(clipLimit=2.0, tileGridSize=(8, 8))
- 3. enhanced_img = clahe.apply(gray_img)

IAȘI LA PICOMATICA SI C

2. Arhitectura preliminară a soluției

- 4.blurred_img = cv2.GaussianBlur(input_img, (5, 5), 0)
- 5. _, binary_img = cv2.threshold(blurred_img, 0, 255, cv2.THRESH_BINARY + cv2.THRESH_OTSU)
- 6. kernel = cv2.getStructuringElement(cv2.MORPH_ELLIPSE, (3, 3))
- 7. opened_img = cv2.morphologyEx(binary_img, cv2.MORPH_OPEN, kernel, iterations=2)

2. Arhitectura preliminară a soluției

- 8. dist_transform = cv2.distanceTransform(opened_img, cv2.DIST_L2, 5)
- 9. sure_bg = cv2.dilate(opened_img, kernel, iterations=3)
- 10. unknown = cv2.subtract(sure_bg, sure_fg)
- 11. _, markers = cv2.connectedComponents(sure_fg)



2. Arhitectura preliminară a soluției

- 8. cv2.watershed(img_for_watershed, markers)
- 9. sure_bg = cv2.dilate(opened_img, kernel, iterations=3)
- 10. pixelAccuracy = (TP + TN) / (TP + TN + FP + FN)
- print(f"Pixel accuracy is {pixelAccuracy * 100:.2f}%")
- # Jaccard Index
- IoU = TP / (TP + FN + FP) if (TP + FN + FP) != 0 else 0
- print(f"Area of overlap/Area of Union (IoU) is {IoU * 100:.2f}%")

2. Arhitectura preliminară a soluției

- 10. # Precision
- precision = TP / (TP + FP) if (TP + FP) != 0 else 0
- print(f"Precision is {precision * 100:.2f}%")
- # Recall
- recall = TP / (TP + FN) if (TP + FN) != 0 else 0
- print(f"Recall is {recall * 100:.2f}%")
- # Dice similarity coefficient
- F_measure = (2 * recall * precision) / (recall + precision) if (recall + precision) != 0 else 0
- print(f"F_measure is {F_measure:.2f}")

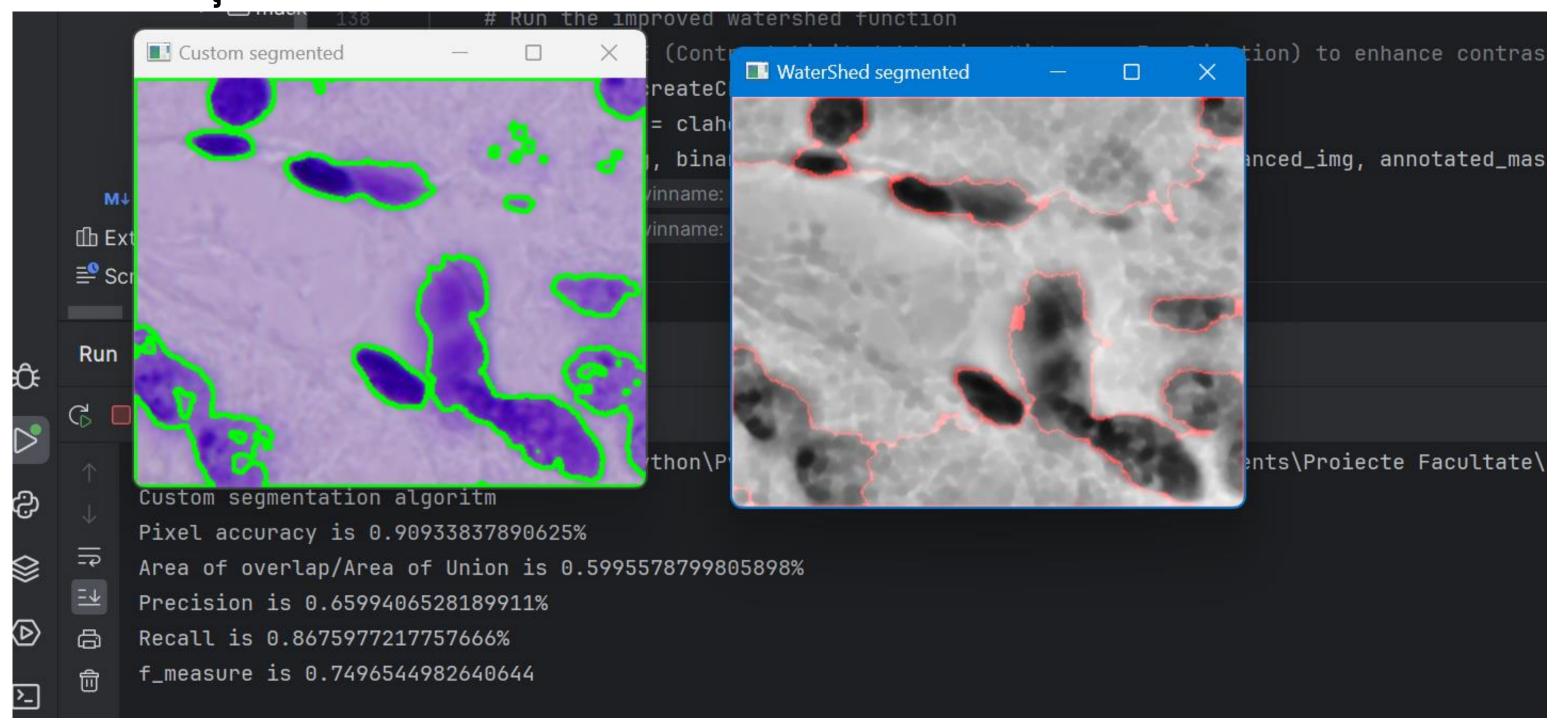
3. Evaluarea Preliminară a Soluției

- · Metodologia de evaluare: accuratete, Jaccard Index, precizie, recall, F_measure
- · Setul de date: Celule de diferite marimi si forme(RGB sau greyscale) care au venit cu un set de masti annotate
- Exemple de cazuri de test:



Rezultate Preliminare

• Rezultate obținute:





5. Concluzii Preliminare

- · Rezumatul progresului: Un algoritm creat intuitiv despre ce ar presupune segmentarea imaginii in mod eficient si algoritmul classic watershed
- · Limitările soluției actuale: pentru imagini RGB, nivelurile de intensitate in masca sunt inversate , celulele se suprapun
- · Potențiale îmbunătățiri: Adaugarea si compararea cu alti algoritmi de segementarea in cautarea unuia cu accuratete mai ridicata

6. Direcții Viitoare

- Paşi următori: Pentru algoritmi deja implementati watershed trebuie sa poata recunoste mai concret marginile unei celule si in algoritmul custom putem aborda mai eficient zgomotele
- Plan de implementare: Adaugarea de transformari morfologice Obiectivele finale: ne-am dori sa putem obtine o serie de algoritmi din care sa putem alege care este cel mai eficient in functie de statistici